# Datakwaliteit hommelopnames

Oct 2, 2026 · @Khaleel Alaqel

De dataset is bruikbaar voor een eerste model, maar vijf punten bepalen hoe betrouwbaar dat model wordt. Het grootste punt: 60% van de opgenomen seconden heeft geen label, en het is niet duidelijk wat dat betekent. Eén punt (dubbele rijen) lossen wij zelf op; voor de andere vier staan onderaan gerichte vragen.

## De dataset in het kort

We hebben 150 WAV-opnames bekeken, samen 9.198 seconden (2 uur en 33 minuten), met het labelbestand `buzzdetection_labels.csv` en het feature-bestand uit `preprocessdata.py`. Eén rij in de dataset is één seconde geluid met 64 features.

| Opnamedag | Samplerate | Bestanden | Seconden | Waarvan gelabeld |
|---|---|---|---|---|
| 26 mei 2026 | 16 kHz | 138 | 8.092 | 3.198 (40%) |
| 24 april 2026 | 384 kHz | 1 | 55 | 0 |
| 13 april 2026 | 384 kHz | 6 | 300 | 300 (100%) |
| 8 april 2026 | 384 kHz | 1 | 533 | 0 |
| 24 maart 2026 | 384 kHz | 4 | 218 | 218 (100%) |

De labels gebruiken vijf klassen: `radio`, `voice`, `noise`, `buzz` en `flight`.

## 1. 60% van de seconden heeft geen label

Van de 9.198 seconden hebben er 5.482 geen label, en we weten niet of dat "niets te horen" of "niet beluisterd" betekent.

- 55 bestanden zijn volledig gelabeld, 28 gedeeltelijk en 67 helemaal niet.
- Op 26 mei is tot ongeveer 10:05 bijna elke seconde gelabeld. Daarna zijn alleen nog losse momenten gelabeld, vooral `flight` en `buzz`, met ongelabelde seconden ertussen.
- De klasse `silence` uit de README komt in het labelbestand niet voor.

**Waarom dit telt:** als "geen label" achtergrondgeluid is, hebben we een grote extra klasse om mee te trainen. Als die seconden niet beluisterd zijn, mogen we ze niet gebruiken en blijft er 40% van de data over.

## 2. De 16 kHz- en 384 kHz-opnames klinken verschillend

De 12 opnames op 384 kHz hebben duidelijk andere feature-waarden dan de 138 opnames op 16 kHz, ook binnen dezelfde klasse. De tabel vergelijkt alleen seconden met het label `radio`; het script zet alle audio eerst om naar 16 kHz.

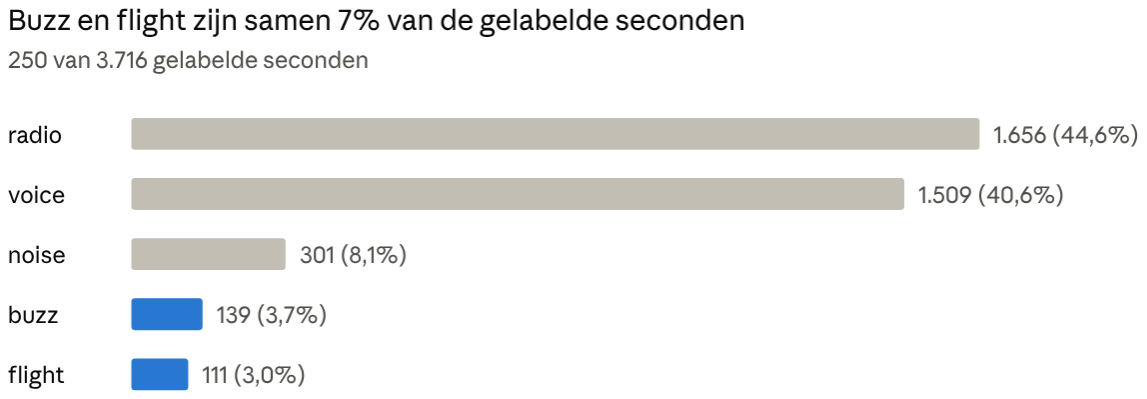
| Feature (mediaan, alleen `radio`) | 16 kHz-opnames | 384 kHz-opnames |
|---|---|---|
| Spectral centroid (Hz) | 1.016 | 1.610 |
| Spectral rolloff (Hz) | 2.115 | 3.786 |
| Zero-crossing rate | 0,057 | 0,091 |

Ter vergelijking: tussen de vijf klassen onderling ligt de mediaan van de spectral centroid tussen 1.022 en 1.203 Hz. Het verschil tussen de twee soorten opnames is dus groter dan het verschil tussen de klassen.

**Waarom dit telt:** een model kan leren welke recorder het hoort in plaats van welk gedrag. Dat risico is het grootst bij `buzz`, omdat 50 van de 139 `buzz`-seconden uit de 384 kHz-opnames komen.

## 3. Weinig voorbeelden van buzz en flight

De twee klassen waar het project om draait zijn veruit de kleinste.




Feature-bestand na ontdubbelen · 3.716 gelabelde seconden uit 83 opnames

De voorbeelden zijn ook weinig gespreid. De `buzz`-seconden komen uit 13 bestanden, en meer dan de helft ervan uit maar 2 bestanden. Labels komen bovendien in aaneengesloten blokken voor, dus seconden uit hetzelfde bestand lijken sterk op elkaar.

**Waarom dit telt:** met zo weinig en zo geclusterde voorbeelden is een hoge score snel misleidend. We splitsen train en test daarom per bestand en beoordelen het model per klasse, niet op de totale accuracy.

## 4. Labels en audio sluiten niet overal op elkaar aan

Van de 3.797 labels hebben er 81 geen bijbehorende audio.

| Tijdstip in labelbestand | Labels zonder audio | Wat er aan de hand is |
|---|---|---|
| 13 april, 11:31 | 55 | Er is geen bestand `20260413_113100.WAV` |
| 13 april, 11:32 – 11:37 | 22 | Labels lopen door tot seconde 59, de opnames duren ongeveer 55 seconden |
| 24 maart, 12:04 | 4 | Er is geen bestand `20260324_120400.WAV` |

Daarnaast staan er in de kolom `opmerking` twee waarden die we niet kunnen duiden: `(derek)` bij 697 rijen en `background voices` bij 42 rijen die als `radio` zijn gelabeld.

**Waarom dit telt:** de koppeling tussen label en geluid loopt via het tijdstip. Als labels doorlopen na het einde van een opname, is het mogelijk dat labels op 13 april een paar seconden verschoven zijn ten opzichte van het geluid. Dat controleren we door fragmenten te beluisteren.

## 5. Elke rij staat dubbel in het feature-bestand

Het bestand `bee_features_per_second.csv` bevat 18.396 rijen, maar elke seconde staat er precies twee keer in. Er zijn dus 9.198 unieke seconden.

De oorzaak zit in `preprocessdata.py`: het script zoekt eerst naar `*.WAV` en daarna naar `*.wav` en telt beide lijsten op. Op Windows en macOS maakt het bestandssysteem geen verschil tussen hoofdletters en kleine letters, waardoor elk bestand twee keer wordt ingelezen.

**Waarom dit telt:** met dubbele rijen kan dezelfde seconde in de trainset en in de testset terechtkomen, en dan lijkt een model beter dan het is. Dit lossen wij zelf op door het script aan te passen en het bestand opnieuw te genereren. Alle cijfers in dit document zijn al gebaseerd op de ontdubbelde data.

## Vragen aan de opdrachtgever

De eerste vraag is de belangrijkste: het antwoord bepaalt hoeveel data we kunnen gebruiken.

1. **Wat betekent een seconde zonder label?** Is daar niets relevants te horen, of is die seconde niet beluisterd? Geldt hetzelfde voor de 67 bestanden zonder enig label?
2. **Zijn de 384 kHz-opnames met een andere recorder of op een andere plek gemaakt** dan de 16 kHz-opnames? Moet het model straks op beide soorten opnames werken?
3. **Zijn er meer opnames met `buzz` of `flight`**, of kunnen de ongelabelde opnames daarop worden nagelopen?
4. **Bestaan de opnames van 13 april 11:31 en 24 maart 12:04 nog?** En hoe is bij het labelen het tijdstip van een seconde bepaald?
5. **Wat betekenen `(derek)` en `background voices`** in de kolom `opmerking`?
6. **Hoort `silence` nog bij de klassen?** De README noemt deze klasse, het labelbestand niet.
7. **Hoe is het verschil tussen `buzz` en `flight` vastgesteld**, en heeft één persoon alle labels gemaakt?

## Voorgestelde volgende stappen

De eerste twee stappen kunnen we nu al doen; de laatste twee hangen af van de antwoorden hierboven.

1. Het script aanpassen en het feature-bestand opnieuw genereren, zonder dubbele rijen.
2. Een steekproef beluisteren: `buzz`-seconden en de opnames van 13 april, om te controleren of label en geluid bij elkaar passen.
3. Beslissen wat we doen met de ongelabelde seconden en met de 384 kHz-opnames.
4. Een eerste model trainen met een train/test-splitsing per bestand, en dat per klasse beoordelen.